# PART 1

# 단층 퍼셉트론(SLP)

1장 회귀분석

2장 이진판단

3장 선택분류

딥러닝 & 강화학습 담당 이재화 강사

# 이 장에서 다를 내용

- 1. 불량 철판 판별 문제
- 2. 선택분류 문제의 신경망 처리 방법
- 3. 소프트맥스 함수와 소프트맥스 교차 엔트로피
- 4. 시그모이드 함수와 소프트맥스 함수의 관계
- 5. 불량 철판 판별 신경망 구현과 실행

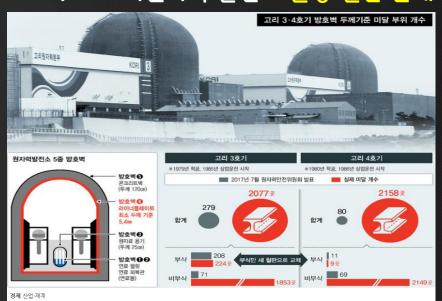
실습에 사용할 데이터셋: faults.csv

#### 3.1 불량 철판 판별 문제

#### 2011.03 후쿠시마 원자력 발전소 사고



#### 2018.05 고리원자력 발전소 불량 철판 문제



[단독] 고리 3·4호기, 철판 4235곳이 '두께 불량'…30년간 몰 랐다

#### 고리원전 '불량 철판' 철저한 조사 촉구

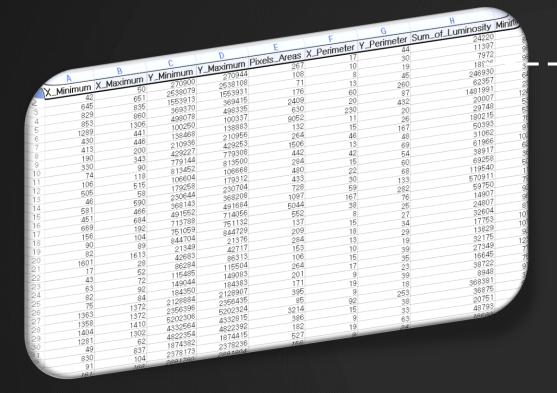
탈핵부산연대, 규탄 기자회견

시민단체, 원자력발전소 철판 '두께 불량' 대책 마련 촉구

2016년부터 부식 점검 시작했으나 올해까지 9998곳 발견, 안전성 조사 필요

박호경 기자(=부산) | 2019-10-08 15:53:29 | 2019-10-08 15:53:38

#### 3.1 불량 철판 판별 문제



one\_hot vector

※ 7가지 철판 불량 상태



※ 27가지 특징값



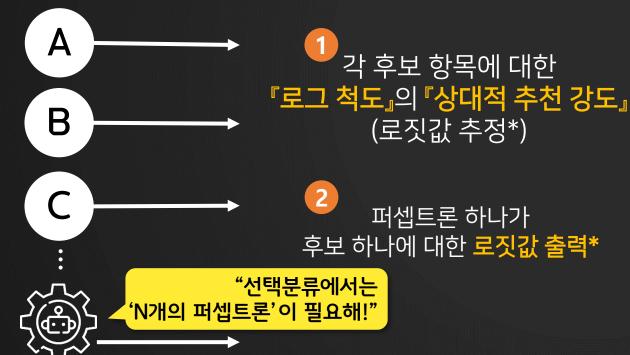
#### 3.2 선택분류 문제의 신경망 처리

# 선택 분류 문제

: 몇 가지 정해진 후보 가운데 하나를 골라 답하는 문제.

: 이진판단과 성격이 비슷.

# 각 후보 항목



# 로짓값

- : 상대적인 가능성을 『로그』 로 이용해 나타낸 값
- : 로짓값의 표현 대상은 각 후보 항목을 답으로 추정할 확률

$$A \rightarrow 3$$

$$e^{3-1} = e^2 = 7.39$$

print(np.exp(3-1))

**B** → 1

7.38905609893065

→ A를 답으로 추정할 확률이 B보다 7.39배 크다.

 $A \rightarrow 36.5$ 

$$e^{3-1} = e^2 = 7.39$$

 $B \rightarrow 34.5$ 

→ A를 답으로 추정할 확률이 B보다 7.39배 크다.

★ 로짓값 사이의 「차이」가 중요

#### 3.2 선택분류 문제의 신경망 처리

# 선택 분류 문제

: 몇 가지 정해진 후보 가운데 하나를 골라 답하는 문제.

: 이진판단과 성격이 비슷.

#오늘도 공부하는 라이언

선택분류만 생각한다면 로짓값들을 구하는 것으로 충분하지 않을까?!

#오늘도 공부하는 라이언

로짓값이 크면 자연스럽게 확률도 커지니까! 우린 그냥 가장 큰 로짓값만 선택하면 되는거 아냐?

#인공지능 비서 에이림

"아쉽게도 로짓값만으로는 마땅한 학습방법을 찾기가 힘들어... ㅠㅠ"

# 딥러닝 연구가 한동한 답보 상태에 빠졌습니다. ------



## 신경망이 추정한 확률분포



교차 엔트로피



정답이 나타내는 확률분포



#**손실함수** 삼아 학습을 수행하면 신경망의 <u>선택을 점점 더 정답에 근접 시킬 수 있음</u>

> 복수의 후보 항목들에 대한 로짓값 벡터를 확률분포 벡터로 변환하는 함수가 필요.



#softmax

이러한 확률분포와 정답에 나타난 확률분포 사이의 교차 엔트로피를 계산해주는 함수의 필요성

#### #확률값 벡터

# 2 #손실함수 편미분 계산

3.3 소프트맥스 함수



P\_0.0 P\_0.1 P\_0.2 P\_0.3 P\_0.4 P\_0.5 P\_0.6 P\_1.1 P\_1.2 P\_1.3 P\_1.4 P\_1.5 P\_1.0 P\_1.6

→ 확률분포, 즉 각 후보항목이 정답일 확률값들로 구성된 벡터

:『**로짓값 벡터**』를 『**확률분포 벡터**』로 변환해주는 비선형 함수

로짓값들은 후보항들에 대한 선택확률을 1.1 *『로그 척도』 로 표현한 것* 

#로짓값 벡터

SOFTMAX()

1 #손실 함수 계산

로짓값 벡터에서 『최대항』 이 1.2 어느 것인지만 확인하면, 신경망이 『어느 후보를 골랐는지 바로 확인 가능』 출력 크기 [N,7]

L_0.0	L_0.1	L_0.2	L_0.3	L_0.4	L_0.5	L_0.6
L_1.0	L_1.1	L_1.2	L_1.3	L_1.4	L_1.5	L_1.6

선택분류를 위한 손실함숫값도 1.1 이 『로짓값 벡터』를 이용하면 바로 계산 가능

굳이 확률값으로 변환하지 않고

가중치 :[27,7]

편향:[7]

#퍼셉트론

P1

P2

P3

P4

P5 P6

D\_0.25

D\_1.25

D\_0.26

D\_1.26

로짓값 벡터를 확률값 벡터 즉. 2.1 softmax()를 거쳐야 하는 이유 :

1.2

역전파에서 『손실함수에 대한 편미분』을 구할 때 이 확률 분포가 필요

『로짓값으로도 순전파의 모든 처리 가능』

#데이터 ' [N,27]

411	- 1	
л	200	_
	STREET, SQUARE,	
83333		

-1	D_0.0
-1	D_1.0

D\_0.1  $D_{0.2}$ D\_1.2 D\_1.1

P0

 $D_{0.24}$ ••• D 1.24

미니배치 크기: N 데이터 특성: 27

#### 3.3.0 소프트맥스 함수 일반식 도출과정



소프트맥스 함수의 성질들을 이용한 『소프트맥스 함수의 일반식』

$$y_i = \frac{e^{x_i}}{e^{x_1} + e^{x_2} + \dots + e^{x_n}}$$

(일반식:계산과정에서 오류 발생)



$$y_i = \frac{e^{x_i - x_k}}{e^{x_1 - x_k} + e^{x_2 - x_k} + \dots + e^{x_n - x_k}}$$

( 변형식 )

이번 월드컵 4강팀의 우승 가능성을 어떻게 예상하시나요?

그 말인 즉,

대한민국은 47.9%, 미국은 17.6% 호주는 21.5%, 독일은 13.0% 으로 우승확률을 예상하는 거군요?!



네, 우선 로짓값으로 대한민국 2.0 미국 1.0 호주 1.2 독일 0.7점을 주겠습니다.



# 연산 과정

 $e^{2.0}:e^{1.0}:e^{1.2}:e^{0.7}$ 

= 7.39 : 2.72 : 3.32 : 2.01



# 비율 유지 및 # 전체 합이 1이 되는 비율

= 0.479 : 0.176 : 0.215 : 0.130



$$y_i = \frac{e^{x_i}}{e^{x_1} + e^{x_2} + \dots + e^{x_n}}$$

#### 소프트맥스

'소프트맥스'라는 단어는 max 함수와 비슷한 의미 (max 함수의 약화된 버전)

max함수와 비슷하게 큰 값을 강조, 작은 값은 약화 효과를 갖는다.

e를 밑으로 하는 지수함수를 취하기 때문.

#### 3.3.1 소프트맥스 함수 변형식이 필요한 이유 그리고 도출과정

소프트맥스 함수의 성질들을 이용한 『소프트맥스 함수의 일반식』

$$y_i = \frac{e^{x_1}}{e^{x_1} + e^{x_2} + \dots + e^{x_n}}$$

(일반식:계산과정에서 오류 발생



$$y_{i} = \frac{e^{x_{i} - x_{k}}}{e^{x_{1} - x_{k}} + e^{x_{2} - x_{k}} + \dots + e^{x_{n} - x_{k}}}$$
(변형식)

에러 1. overflow 발생 및 inf

문제발생 문제발생!

# np.exp(10000) C:\Users\leeyua\AppData\Local\Continuum\anaconda3\lib \site-packages\ipykernel\_launcher.py:1: RuntimeWarnin g: overflow encountered in exp """Entry point for launching an IPython kernel. inf

에러 2. 모든 값이 아주 큰 음수로 쏠리게 되면 분자, 분모 값 0 수렴 및 0 나눗셈 오류 발생

```
print(np.exp(-100))
print(np.exp(-1000))

3.720075976020836e-44
0.0
```

#### Part 1. 단층 퍼셉트론

#### 3.3.1 소프트맥스 함수 변형식이 필요한 이유 그리고 도출과정

소프트맥스 함수의 성질들을 이용한 『소프트맥스 함수의 일반식』

$$y_i = \frac{e^{x_i}}{e^{x_1} + e^{x_2} + \dots + e^{x_n}}$$

(일반식:계산과정에서 오류 발생



$$e^{x_i - x_k}$$

$$y_{i} = \frac{1}{e^{x_{1}-x_{k}} + e^{x_{2}-x_{k}} + \dots + e^{x_{n}-x_{k}}}$$
(변형식)

#### 그 말인 즉,

대한민국은 47.9%, 미국은 17.6% 호주는 21.5%, 독일은 13.0% 으로 우승확률을 예상하는 거군요?! 네, 우선 로짓값으로 대한민국 2.0 미국 1.0 호주 1.2 독일 0.7점을 주겠습니다.

#### # 최댓값을 이용한 overflow 문제 해결

: 최댓값을 찾아 정의식 분모와 분자를 동시에 나눠준다.

: 분자와 분모에 존재하는 항들이 모두 0~1 사이의 값. (overflow 해결)

 $e^{2.0}$ :  $e^{1.0}$ :  $e^{1.2}$ :  $e^{0.7}$ 

최댓값에 해당하는  $e^{2.0}$ 찾아 빼준다.

 $\rho^{0.0}$ .  $\rho^{-1.0}$ .  $\rho^{-0.8}$ .  $\rho^{-1.3}$ 

 $e^{2.0}:e^{1.0}:e^{1.2}:e^{0.7}$ 

= 1.00 : 0.37 : 0.45 : 0.27

= 7.39 : 2.72 : 3.32 : 2.01

= 0.479 : 0.176 : 0.215 : 0.130

= 0.479 : 0.176 : 0.215 : 0.130

변형식 도출 결과 == 일반 정의식 도출 결과

#### #0 나눗셈 문제 해결

 $e^{x_k-x_k} = e^0 = 1$  → 분모에 존재하게 되기에, 분모는 언제나 1 보다 커짐으로써 0 나눗셈 문제 또한 해결

#### 3.4 소프트맥스 함수의 편미분

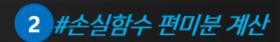


※ 실제 딥러닝 학습에 이용되지 않습니다!



## 편미분 대상은 손실함수를 구해주는 소프트 맥스 교차 엔트로피

#### #확률값 벡터

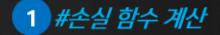


P_0.0	P_0.1	P_0.2	P_0.3	P_0.4	P_0.5	P_0.6
P_1.0	P_1.1	P_1.2	P_1.3	P_1.4	P_1.5	P_1.6

→ 확률분포, 즉 각 후보항목이 정답일 확률값들로 구성된 벡터







출력 크기 [N,7]

L_0.0	L_0.1	L_0.2	L_0.3	L_0.4	L_0.5	L_0.6
L_1.0	L_1.1	L_1.2	L_1.3	L_1.4	L_1.5	L_1.6

#### 3.5 소프트맥스 교차 엔트로피



# 신경망의 로짓값 벡터 ←→ 두 확률분포 사이의 교차 엔트로피 ←→ 정답 확률분포 벡터

$$a_1, \dots, a_n$$
 $\downarrow$ 

 $H(\mathbf{P},\mathbf{Q}) = -\sum_{i}^{n} \log \mathbf{q}_{i}$ 

 $y_1, \dots, y_n$ 

확률 분포 P



확률 분포 Q

문제발생 문제발생!



$$H(P,Q) = -\sum p_i \log q_i \approx H(P,Q) = -\sum p_i \log(q_i + \varepsilon)$$



아주 작은 값을 더해줌으로써 문제 해결

※ <mark>미미한 존재</mark>로 별다른 영향을 주지 않는다.

※ 0에 매우 가까운 하한선 역할을 수행

확률의 성질상 모든 원솟값이 항상 0 ~ 1 값을 갖는다.

교차 엔트로피 연산 중 의 값이 들어오게 되면 -inf , <mark>0</mark>의 값을 출력

print(np.log(0)); print(np.log(1))

-inf 0.0

 $print(np.log(0 + \epsilon))$  $print(np.log(1 + \epsilon))$ 

 $\varepsilon = 1.0e-10$ 

-23.025850929940457 .000000082690371e-10

#### 3.6 소프트맥스 교차 엔트로피 편미분

# 신경망의 로짓값 벡터

$$x_1, ..., x_n$$
 $\downarrow$ 
softmax()
 $\downarrow$ 
확률 분포  $\mathbb{Q}$ 
 $q_1, ..., q_n$ 

# 정답 확률분포 벡터

$$p_1, \ldots, p_n$$

확률 분포 P

$$\frac{\partial H}{\partial x_i} = \mathbf{q}_i - \mathbf{p}_i$$

#### #확률값 벡터

#### 2 #손실함수 편미분 계산

P_0.0	P_0.1	P_0.2	P_0.3	P_0.4	P_0.5	P_0.6
P_1.0	P_1.1	P_1.2	P_1.3	P_1.4	P_1.5	P_1.6
				:		

→ 확률분포, 즉 각 후보항목이 정답일 확률값들로 구성된 벡터

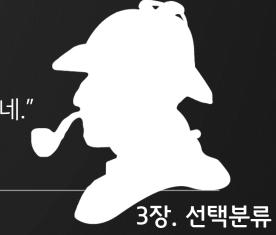


#### SOFTMAX()



출력크기[N,7] L\_0.0 L\_0.1 L\_0.2 L\_0.3 L\_0.4 L\_0.5 L\_0.6 L\_1.0 L\_1.1 L\_1.2 L\_1.3 L\_1.4 L\_1.5 L\_1.6

"지금까지의 과정은 다소 복잡했지, 하지만, 이 하나를 통해 모든것을 관통하게 된다네."



교차 엔트로피 정의식 
$$\frac{\partial H}{\partial x_i} = -\frac{\partial}{\partial x_i} \sum_{k=1}^n p_k \log q_k$$
  $\frac{\partial H}{\partial x_i} = -\frac{\partial}{\partial x_i} \sum_{k=1}^n p_k \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} p_k \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} p_k \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \log q_k$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \frac{\partial}{\partial x_i}$   $\frac{\partial H}{\partial x_i} = -\sum_{k=1}^n \frac{\partial}{\partial x_i} \frac{\partial}{\partial x_i$ 

